

第二讲 统计泛函和影响函数

张伟平

统计与金融系

第二讲 统计泛函与影响函数

2.1	统计泛函	2
2.2	影响函数	12
2.3	高阶导数	20

2.1 统计泛函

■ 在很多时候, 感兴趣的参数往往是分布函数 F 的函数, 记为 $\theta = T(F)$, 称为**统计泛函**.

- 均值: $T(F) = \int x dF(x)$
- 方差 $T(F) = \int (x - \mu)^2 dF(x)$
- 分位数 $T(F) = F^{-1}(p)$
- 相关系数 $\rho(t_1, t_2, t_3, t_4, t_5) = \frac{t_3 - t_1 t_2}{\sqrt{(t_4 - t_1^2)(t_5 - t_2^2)}}$, 其中 $T_1(F) = \iint x dF(x, y)$, $T_2(F) = \iint y dF(x, y)$, $T_3(F) = \int xy dF(x, y)$, $T_4(F) = \int x^2 dF(x, y)$, $T_5(F) = \int y^2 dF(x, y)$
- Mann-Whitney 泛函: $T(F, G) = P(X \leq Y | X \sim F, Y \sim G) = \int F(x) dG(x)$.

记 F_n 为经验分布函数, 则统计泛函 $\theta = T(F)$ 的 "Plug-in" 估计为 $\hat{\theta} = T(F_n)$.

Definition

■ 常见统计泛函的 plug-in 估计:

- 样本均值: $T(F_n) = \int x dF_n(x) = \frac{1}{n} \sum_{i=1}^n X_i$
- 样本方差: $T(F_n) = \int x^2 dF_n(x) - \left(\int x dF_n(x) \right)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$
- 样本相关系数:

$$\begin{aligned}\hat{\rho} &= \rho(t_1(F_n), t_2(F_n), t_3(F_n), t_4(F_n), t_5(F_n)) \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}\end{aligned}$$

-
- Mann-Whitney 统计量:

$$T(F_m, G_n) = \int F_m(x) dG_n(x) = \frac{1}{nm} \sum_{i,j} 1\{X_i \leq Y_j\}$$

- 多元协方差矩阵: k 维随机变量 $X \sim F$, 记 $F_n(x) = \frac{1}{n} \sum_{i=1}^n 1\{X_i \leq x\} = \frac{1}{n} \sum_{i=1}^n 1\{X_{i1} \leq x_1, \dots, X_{ik} \leq x_k\}$, 则由协方差矩阵

$$\begin{aligned} T(F) &= \int (x - \int y dF(y)) (x - \int y dF(y))^T dF(x) \\ &= \frac{1}{2} \iint (x - y)(x - y)^T dF(x) dF(y) \end{aligned}$$

知样本协方差矩阵为

$$\begin{aligned} T(F_n) &= \int (x - \int y dF_n(y)) (x - \int y dF_n(y))^T dF_n(x) \\ &= \frac{1}{2} \iint (x - y)(x - y)^T dF_n(x) dF_n(y) \end{aligned}$$

连续性

称 $T : \mathcal{F} \mapsto R$ 在 F_0 处连续, 如果 $F_n \Rightarrow F_0$ 蕴含 $T(F_n) \rightarrow T(F_0)$.

Definition

例: 若 $F_n = (1 - \frac{1}{n})F_0 + \frac{1}{n}\delta_{a_n}$, $a_n/n \rightarrow \infty$, 则 $T(F) = \int x dF$ 在 F_0 处不连续.

事实上, 由于对任何有界函数 ψ 有

$$\int \psi dF_n = (1 - n^{-1}) \int \psi dF_0 + n^{-1} \psi(a_n) \rightarrow \int \psi dF_0$$

故有 $F_n \rightarrow F_0$. 但是

$$T(F_n) = (1 - n^{-1})T(F_0) + n^{-1}a_n \rightarrow \infty$$

.


■ Plug-in 估计 $T(F_n)$ 是 $T(F)$ 的一个好估计吗?

■ The Glivenko-Cantelli 定理保证了 $F_n \rightarrow F, a.s.$, 是不是也意味着 $T(F_n) \rightarrow T(F), a.s.$?

■ 答案是: 有时候可以, 有时候不对!

■ 例如 Plug-in 密度估计

泛函 $T(F) = \frac{d}{dx}F(x)$ 的 plug-in 估计显然不是相合估计:



■ 因此什么时候 plug-in 估计为相合估计? 需要对 $T(F)$ 做一些光滑性假设 (可导性)

■ 如何对一个泛函求导? 我们需要推广导数的定义

Gâteaux derivative

$$\frac{dT(F)}{dF} = \lim_{\epsilon \rightarrow 0} \left[\frac{T(F_\epsilon) - T(F)}{\epsilon} \right]$$

- 一个泛函 T 在 F 处沿方向 G 的 Gâteaux 导数定义为

$$L_F(T; G) = \lim_{\epsilon \rightarrow 0} \left[\frac{T((1 - \epsilon)F + \epsilon G) - T(F)}{\epsilon} \right]$$

- 一个等价定义为先定义 $D = G - F$, 从而

$$L_F(T; D) = \lim_{\epsilon \rightarrow 0} \left[\frac{T(F + \epsilon D) - T(F)}{\epsilon} \right]$$

- 从数学上来看, Gâteaux 导数是方向导数在泛函分析中的推广

- 从统计上来看, Gâteaux 导数表示的是一个统计泛函在一小部分被分布 G 污染下的变化速率

例：密度 $f(x)$ 的 Gâteaux 导数

■ 设 F 为连续的 CDF, G 为在点 x_0 处退化的随机变量的分布函数

■ 那么 $T(F) = f(x_0)$ 的 Gâteaux 导数是什么?

$$\begin{aligned} L_F(T; G) &= \lim_{\epsilon \rightarrow 0} \left[\frac{\frac{d}{dx} \{(1 - \epsilon)F(x) + \epsilon G(x)\}_{x=x_0} - \frac{d}{dx} F(x)|_{x=x_0}}{\epsilon} \right] \\ &= \lim_{\epsilon \rightarrow 0} \left[\frac{(1 - \epsilon)f(x_0) + \epsilon g(x_0) - f(x_0)}{\epsilon} \right] \\ &= \infty \end{aligned}$$

■ 因此, 即便 F 和 F_ϵ 相差无限小, 但是 $T(F_n)$ 和 $T(F)$ 可以相差无穷大

■ 本例中 Glivenko-Cantelli 定理并不蕴含 $T(F_n) \rightarrow T(F), a.s.$

Hadamard 导数

■ 事实上假设 Gâteaux 可导也还是比较弱，不能保证 $T(F_n) \rightarrow T(F)$, *a.s.*

■ 即使是 Gâteaux 导数存在，也可能不是在全域上唯一存在的。这就是 Hadamard 可导性所想解决的

一个泛函 T 称为是 Hadamard 可微的，如果对任意序列 $\epsilon_n \rightarrow 0$ 和满足 $\sup_x |D_n(x) - D(x)| \rightarrow 0$ 的函数 D_n ，有

$$\frac{T(F + \epsilon_n D_n) - T(F)}{\epsilon_n} \rightarrow L_F(T, D)$$

Definition

定理 1. 如果泛函 T 是 Hadamard 可微的，则 $T(F_n) \rightarrow T(F)$, *in P.*

Gâteaux 导数与 Hadamard 导数

■ 设 \mathcal{F} 表示所有分布函数, \mathcal{D} 表示由 \mathcal{F} 所生成的线性空间。记 $T((1-\epsilon)F + \epsilon G) = T(F + \epsilon D)$, 其中 $D = G - F \in \mathcal{D}$.

■ 由 Gâteaux 导数 $L_F(D)$ 的定义知

$$\lim_{\epsilon \downarrow 0} \left| \frac{T(F + \epsilon D) - T(F)}{\epsilon} - L_F(D) \right| \rightarrow 0.$$

因此 $T(F + \epsilon D) - T(F) \approx \epsilon L_F(D) + o(\epsilon)$, 其中误差项 $o(\epsilon) \rightarrow 0$ 当 $\epsilon \rightarrow 0$ 。

■ Hadamard 导数则要求误差项 $o(\epsilon)$ 为一个紧集上的一致小量。对线性空间 \mathcal{D} 赋一度量 d , 此时泛函 $T(F)$ 在 F 处是 Hadamard 可导的, 如果存在 \mathcal{D} 上的线性泛函 L_F , 使得对任意 $\epsilon_n \rightarrow 0$ 和 $\{D, D_1, D_2, \dots\} \subset \mathcal{D}$ 满足 $d(D_n, D) \rightarrow 0$ 和 $F + \epsilon_n D_n \in \mathcal{F}$ 有

$$\lim_{n \rightarrow 0} \left(\frac{T(F + \epsilon_n D_n) - T(F)}{\epsilon_n} - L_F(D_n) \right) = 0.$$

2.2 影响函数

污染一个点质量

■ 在稳健统计中，通过额外的一小部分点来污染一个总体分布已经有很长的历史

■ 统计学家一般并不直接使用 Gâteaux 导数，而是使用一种特殊的场合，此时称为**影响函数 (Influence function)**，即 G 为在点 x 处退化的随机变量之分布函数：

$$G(u) = \delta_x(u) = \begin{cases} 0, & \text{if } u < x \\ 1, & \text{if } u \geq x \end{cases}$$

■ 影响函数常记为 x 的函数：

$$IF(x; T, F) = \lim_{\epsilon \rightarrow 0} \left[\frac{T((1 - \epsilon)F + \epsilon\delta_x) - T(F)}{\epsilon} \right]$$

■ 与其密切相关的是**经验影响函数**:

$$IF(x; T, F_n) = \lim_{\epsilon \rightarrow 0} \left[\frac{T((1 - \epsilon)F_n + \epsilon\delta_x) - T(F_n)}{\epsilon} \right]$$

■ 例: 设 $T(F) = F(A)$, 其中 A 为给定的事件. 则记 $F_t = (1 - t)F + t\delta_x$, 从而

$$\frac{T(F_\epsilon) - T(F)}{\epsilon} = 1_A(x) - F(A)$$

■ 例: 设 $T(F) = \mu(F) = \int x dF$, 则

$$\frac{T(F_\epsilon) - T(F)}{\epsilon} = x - T(F)$$

■ 例: 设 $T(F) = Var_F(X) = \int (x - \mu(F))^2 dF(x)$, 则

$$\begin{aligned} \left. \frac{d}{dt} T(F_t) \right|_{t=0} &= \frac{d}{dt} \int (x - \mu(F_t))^2 dF_t(x) \\ &= \int (x - \mu(F))^2 d(G - F)(x) \end{aligned}$$

$$\begin{aligned}
& + 2 \int (x - \mu(F))(-1)\dot{\mu}(F; G - F)dF(x) \\
& = \int (x - \mu(F))^2 d(G - F) \\
& = \int \{(x - \mu(F))^2 - \sigma_F^2\} dG(x) \\
& = (x - \mu(F))^2 - \sigma_F^2
\end{aligned}$$

■ 例. $T(F) = F^{-1}(1/2)$, 假设 F 有密度 f 且满足 $f(F^{-1}(1/2)) > 0$, 则影响函数

$$\left. \frac{d}{dt} T(F_t) \right|_{t=0} = \left. \frac{d}{dt} F_t^{-1}(1/2) \right|_{t=0}$$

注意 $F_t(F_t^{-1}(1/2)) = 1/2$, 因此

$$\begin{aligned}
0 & = \left. \frac{d}{dt} F_t(F_t^{-1}(1/2)) \right|_{t=0} \\
& = \left. \frac{d}{dt} \{F(F_t^{-1}(1/2)) + t(G - F)(F_t^{-1}(1/2))\} \right|_{t=0}
\end{aligned}$$

$$= f(F^{-1}(1/2)) IF(x; T, F) + (G - F)(F^{-1}(1/2)) + 0$$

故有

$$\begin{aligned} IF(x; T, F) &= -\frac{(G - F)(F^{-1}(1/2))}{f(F^{-1}(1/2))} \\ &= -\frac{\int (1_{(-\infty, F^{-1}(1/2))}(x) - 1/2) dG(x)}{f(F^{-1}(1/2))} \\ &= -\frac{1}{f(F^{-1}(1/2))} \left\{ 1_{(-\infty, F^{-1}(1/2))}(x) - 1/2 \right\} \end{aligned}$$

■ 例. 设 F 有正的密度 f , 则 $T(F) = F^{-1}(p)$ 的影响函数为

$$\begin{aligned} IF(x; T, F) &= -\frac{\int (1_{(-\infty, F^{-1}(p))}(x) - p) dG(x)}{f(F^{-1}(p))} \\ &= \begin{cases} \frac{p-1}{f(F^{-1}(p))}, & x \leq F^{-1}(p) \\ \frac{p}{f(F^{-1}(p))}, & x > F^{-1}(p) \end{cases} \end{aligned}$$

称 $T(F) = \int a(x)dF(x)$ 为线性泛函.

Definition

■ 线性泛函的 Plog-in 估计为

$$T(F_n) = \int a(x)dF_n(x) = \frac{1}{n} \sum_{i=1}^n a(X_i)$$

■ 对线性泛函 $T(F) = \int a(x)dF(x)$, 我们有

- 影响函数 $IF(x; T, F) = a(x) - T(F)$, 经验影响函数 $IF(x; T, F_n) = a(x) - T(F_n)$.
- 对任意 G ,

$$T(G) = T(F) + \int IF(x; T, F)dG(x).$$

- $\int IF(x; T, F)dF(x) = 0$

-
- 记 $\tau^2 = \int IF^2(x; T, F) dF(x)$, 则 $\tau^2 = \int (a(x) - T(F))^2 dF(x)$,
且当 $\tau^2 < \infty$ 时

$$\sqrt{n}(T(F) - T(F_n)) \rightsquigarrow N(0, \tau^2).$$

- 记

$$\hat{\tau}^2 = \frac{1}{n} \sum_{i=1}^n IF^2(X_i; T, F_n) = \frac{1}{n} \sum_{i=1}^n (a(X_i) - T(F_n))^2$$

则 $\hat{\tau}^2 \xrightarrow{P} \tau^2$, 以及 $\hat{se}/se \xrightarrow{P} 1$, 其中 $\hat{se} = \hat{\tau}/\sqrt{n}$, $se = \sqrt{\text{Var}(T(F_n))}$.

- $\frac{\sqrt{n}(T(F) - T(F_n))}{\hat{\tau}} \rightsquigarrow N(0, 1)$.

■ 对非线性泛函有

定理 2. 设统计泛函 $T(F)$ 相对于距离 $d(F, G) = \sup_x |F(x) - G(x)|$ 是 *Hadamard* 可微的, 则

$$\sqrt{n}(T(F_n) - T(F)) \rightsquigarrow N(0, \tau^2),$$

其中 $\tau^2 = \int IF^2(x; T, F)(x) dF(x)$. 同时有

$$\frac{(T(F_n) - T(F))}{\hat{se}} \rightsquigarrow N(0, 1),$$

其中 $\hat{se} = \hat{\tau}/\sqrt{n}$ 以及 $\hat{\tau} = \frac{1}{n} \sum_{i=1}^n IF^2(X_i; T, F_n)$.

■ **非参数 Delta 方法:** 泛函 $T(F)$ 的 $1 - \alpha$ 逐点渐近置信区间为 $T(F_n) \pm z_{\alpha/2} \hat{se}$.

■ **Chain Rule** 设统计泛函 $T(F)$ 对某些函数 $a(t_1, \dots, t_m)$ 有形式 $T(F) = a(T_1(F), \dots, T_m(F))$, 则其影响函数为

$$IF(x; T, F) = \sum_{i=1}^m \frac{\partial a}{\partial t_i} IF_i(x; T, F)$$

其中

$$IF_i(x; T, F) = \lim_{\epsilon \rightarrow 0} \frac{T_i((1 - \epsilon)F + \epsilon \delta_x) - T_i(F)}{\epsilon}.$$

■ 例如样本相关系数 $T(F) = a(T_1(F), T_2(F), T_3(F), T_4(F), T_5(F))$ 的影响函数为

$$IF(x, y; T, F) = \tilde{x}\tilde{y} - \frac{1}{2}T(F)(\tilde{x}^2 + \tilde{y}^2),$$

其中

$$\tilde{x} = \frac{x - \int x dF}{\sqrt{\int x^2 dF - (\int x dF)^2}}, \tilde{y} = \frac{y - \int y dF}{\sqrt{\int y^2 dF - (\int y dF)^2}}.$$

2.3 高阶导数

■ 设 $X_1, \dots, X_n \text{ i.i.d. } \sim B(1, p)$, 则 $\sqrt{n}(\bar{X} - p) \rightsquigarrow N(0, p(1-p))$,
若 $g(p) = p(1-p)$, 则由 Delta 方法知道

$$\sqrt{n}(g(\bar{X}) - g(p)) \rightsquigarrow N(0, p(1-p)(1-2p)^2)$$

特别, 若 $p = 1/2$, 则由于 $g'(1/2) = 0$, 从而 $\sqrt{n}(g(\bar{X}) - g(1/2)) \rightsquigarrow 0$.
因此需要考虑高阶导数。注意到

$$g(p) = g(1/2) + 0 \cdot (p - 1/2) + \frac{1}{2}(-2)(p - 1/2)^2 + o((p - 1/2)^2)$$

从而

$$n(g(\bar{X}) - g(1/2)) = -n(\bar{X} - 1/2)^2 \rightsquigarrow -\frac{1}{4}\chi_1^2$$

■ 考虑泛函 $T : \mathcal{F} \mapsto \mathcal{R}$, 利用实函数 $g(t) = T(F_t)$, $F_t = F + tD$ 在 $t = 0$ 处的 Taylor 展开式:

$$\begin{aligned} g(t) &= g(0) + g'(0)t + \frac{1}{2}g''(0)t^2 + \cdots + \frac{1}{m!}g^{(m)}(0)t^m + o(t^m) \\ &= T(F) + tT'_F(F, D) + \cdots + \frac{1}{m!}T_F^{(m)}(F, D) + o(t^m) \end{aligned}$$

其中 $T_F^{(m)}(F, D) = \left. \frac{d^m}{dt^m} T(F_t) \right|_{t=0}$.

■ 令 $t = \frac{1}{\sqrt{n}}$, $D = \sqrt{n}(F_n - F) = G_n$, 则得到 **Von Mises** 展开:

$$T(F_n) - T(F) = \frac{1}{\sqrt{n}}T'_F(F, G_n) + \cdots + \frac{1}{m!} \frac{1}{n^{m/2}}T_F^{(m)}(F, G_n) + \cdots$$

■ 在很多时候, m 阶导数 $T_F^{(m)}(F, G - F)$ 可以表示为

$$\begin{aligned} T_F^{(m)}(F, G - F) &= \int \cdots \int \psi_m(x_1, \dots, x_m) d(G - F)(x_1) \cdots d(G - F)(x_m) \\ &= \int \cdots \int \psi_{m,F}(x_1, \dots, x_m) dG(x_1) \cdots dG(x_m) \end{aligned}$$

其中 $\psi_{m,F}$ 由 ψ_m 中心化而成:

$$\psi_{1,F} = \psi_1(x) - \int \psi_1 dF,$$

$$\begin{aligned}\psi_{2,F} &= \psi_2(x_1, x_2) - \int \psi_2(x_1, x_2) dF(x_1) \\ &\quad - \int \psi_2(x_1, x_2) dF(x_2) + \iint \psi_2(x_1, x_2) dF(x_1) dF(x_2)\end{aligned}$$

■ 当 $m = 1$ 时候, 一般 $T_F^{(m)}(F, D)$ 为一线性泛函, 则

$$T(F_n) - T(F) \approx \frac{1}{\sqrt{n}} T'_F(F, G_n) = \frac{1}{n} \sum_{i=1}^n \psi_{1,F}(X_i) = \frac{1}{n} \sum_{i=1}^n IF(X_i; T, F)$$

从而

$$\sqrt{n}(T(F_n) - T(F)) \approx \frac{1}{\sqrt{n}} \sum_{i=1}^n IF(X_i; T, F)$$

利用中心极限定理，即可得出极限分布

$$\sqrt{n}(T(F_n) - T(F)) \rightsquigarrow N(0, \tau^2)$$

其中 $\tau^2 = \int IF^2(x; T, F)(x) dF(x)$.

■ 注意到 Fisher 信息量为

$$I(F_{\theta_0}) = \int \left(\left. \frac{\partial}{\partial \theta} \ln f_{\theta}(x) \right|_{\theta_0} \right)^2 dF_{\theta_0}$$

The Cramér-Rao information inequality: 对任意平方可积的统计量 T , 有

$$\begin{aligned} \frac{d}{d\theta} \mathbb{E}_{\theta} T &= \int \frac{\partial}{\partial \theta} T f_{\theta} \mu(dx) \\ \text{Var}(T; F_{\theta}) &\geq \frac{\left[\frac{\partial}{\partial \theta} \mathbb{E}_{\theta} T \right]^2}{I(F_{\theta})} \end{aligned}$$

因此 $T(F_n)$ 是渐近有效的, 仅当

$$IF(x; T, F) = I(F_{\theta_0})^{-1} \frac{\partial}{\partial \theta} (\ln f_{\theta}(x)) \Big|_{\theta_0}$$

■ Jackknife 方差的估计与影响函数之间有渐近关系
对统计泛函 $T_n = T(F_n)$, 定义第 j 个 pseudovalue:

$$T_{nj}^* = nT(F_n) - (n-1)T(F_{(j)})$$

其中 $F_{(j)}$ 为去掉第 j 个点后的经验分布函数. 故 Jackknife 估计为

$$T_n^* = \frac{1}{n} \sum_{j=1}^n T_{nj}^*$$

这些 pseudovalue 的样本方差为

$$V_n = \frac{1}{n-1} \sum_{j=1}^n (T_{nj}^* - T_n^*)^2$$

T_n 方差的 Jackknife 估计为 $\frac{1}{n}V_n$. 带入到影响函数的定义并取 $\epsilon = \frac{-1}{n-1}$ 有

$$\begin{aligned}& \frac{n-1}{-1} \left(T \left(\left(1 - \frac{-1}{n-1} \right) F_n + \frac{-1}{n-1} \delta_{x_j} \right) - T(F_n) \right) \\&= (n-1) [T(F_n) - T(F_{(j)})] \\&= T_{nj}^* - T(F_n)\end{aligned}$$

注意 $\left(1 - \frac{-1}{n-1} \right) F_n + \frac{-1}{n-1} \delta_{x_j} = F_{(j)}$. 因此, Jackknife pseudo-value 给出了影响函数的一个近似.

■ 基于影响函数的稳健性度量

Gross error sensitivity of T at F

$$\gamma^* = \gamma^*(T, F) = \sup_{\{x: IF(x; T, F) \text{ exists} \}} |IF(x; T, F)|$$

用来度量给 F 在一个点上的小扰动后 T 的最大变化. 若 $\gamma^*(T, F) < \infty$, 则称 T 在 F 处是 B-robust 的. (B is for bias).

Local shift sensitivity

$$\lambda^* = \lambda^*(T, F) = \sup_{\{x \neq y: F(x; T, F) \text{ and } IF(y; T, F) \text{ both exist}\}} \frac{|IF(y; T, F) - IF(x; T, F)|}{|y - x|}$$

Reject point 若 F 是对称的 (且对称中心为原点), 则称

$$\rho^* = \rho^*(T, F) = \inf\{r > 0 : IF(x; T, F) = 0, \quad \forall |x| > r\}$$

为拒绝点. 若不存在这样的 r , 则 $\rho^* = \infty$. 所有大于 ρ^* 的点都被完全拒绝.

Breakdown point 记 $F_\epsilon = (1 - \epsilon)F + \epsilon\delta_x$. 则

$$\epsilon^* = \inf\{\epsilon > 0 : \sup_x |T(F) - T(F_\epsilon)| = \infty\}$$

称为估计量 T 的崩溃点.

■ 例. 考虑统计泛函 $T = T(F) = \int x dF$, 则 $IF(x; T, \Phi) = x - T(F)$. 从而 $\gamma^* = \infty$, $\lambda^* = 1$, $\rho^* = \infty$, $\epsilon^* = 0$, 故均值受舍入误差影响不大, 但是对异常点比较敏感.

■ 在大部分情况下，展开到一阶导数足够了，此时极限分布为正态分布。但是，在一些例子中一阶导数为 0，此时就需要展开到二阶导数项。

■ **Serfling's Condition A_m** 假设

$$\text{Var}_F(\psi_{k,F}(X_1, \dots, X_k)) \begin{cases} = 0 & \text{for } k < m \\ > 0 & \text{for } k = m \end{cases}$$

$$\text{Let } R_{mn} = T(F_n) - T(F) - \frac{1}{m!} T_F^{(m)}(F_n - F),$$

$$\text{then } n^{m/2} R_{mn} = o_p(1).$$

定理 3 (Serfling's theorem A). 设 X_1, \dots, X_n *i.i.d* $\sim F$, 泛函 T 满足 *Serfling* 条件 A_1 . 记 $\mu(T, F) = E_F \psi_{1,F}(X_1) = 0$ 以及 $\tau^2 = \text{Var}(\psi_{1,F}(X_1))$, 假设 $\tau^2 < \infty$, 则

$$\sqrt{n}(T(F_n) - T(F)) \rightsquigarrow N(0, \tau^2)$$

证明. 根据条件 A_1 的第二条,

$$\begin{aligned}\sqrt{n}(T(F_n) - T(F)) &= o_p(1) + \sqrt{n}T'_F(F, G_n) \\ &= o_p(1) + \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi_{1,F}(X_i) \rightsquigarrow N(0, \tau^2).\end{aligned}$$

□

定理 4 (Serfling's theorem B). 设 $X_1, \dots, X_n i.i.d \sim F$, 泛函 T 满足 Serfling 条件 A_2 且 $\psi_{2,F}(x, y) = \psi_{2,F}(y, x)$, 以及 $E_F \psi_{2,F}^2(X_1, X_2) < \infty$, $E_F |\psi_{2,F}(X_1, X_1)| < \infty$, $E_F \psi_{2,F}(x, X_2) = 0$, 定义 $A: \mathcal{L}_2(F) \mapsto \mathcal{L}_2(F)$:

$$Ag(x) = \int \psi_{2,F}(x, y)g(y)dF(y), g \in \mathcal{L}_2(F)$$

记 $\{\lambda_k\}$ 为 A 的特征根, 则有

$$n(T(F_n) - T(F)) \rightsquigarrow \sum_{k=1}^{\infty} \lambda_k Z_k^2$$

其中 $\{Z_k\}$ 为 $i.i.d$ 标准正态随机变量, λ_k 依赖于 F 和泛函 T 。

证明. 由条件 A_2 我们有

$$\begin{aligned} n(T(F_n) - T(F)) &= n \left\{ T(F_n) - T(F) - \frac{1}{2!} T_F''(T, F_n - F) \right\} \\ &\quad + \frac{n}{2!} T_F''(T, F_n - F) \end{aligned}$$

$$= o_p(1) + \frac{n}{2} \iint \psi_{2,F}(x_1, x_2) dF_n(x_1) dF_n(x_2)$$

记运算 A 的正交特征向量函数和相应的特征根分别为 $\{\phi_k\}$ 和 $\{\lambda_k\}$, 则 $A\phi_k = \lambda_k\phi_k$, 以及

$$\psi_{2,F}(x, y) = \sum_{k=1}^{\infty} \lambda_k \phi_k(x) \phi_k(y)$$

在 $\mathcal{L}_2(F \times F)$ 中成立。因此

$$\begin{aligned} & \frac{n}{2} \iint \psi_{2,F}(x_1, x_2) dF_n(x_1) dF_n(x_2) \\ &= \frac{n}{2} \iint \sum_{k=1}^{\infty} \lambda_k \phi_k(x) \phi_k(y) dF_n(x) dF_n(y) \\ &= \frac{n}{2} \sum_{k=1}^{\infty} \lambda_k \left\{ \int \phi_k dF_n \right\}^2 = \frac{1}{2} \sum_{k=1}^{\infty} \lambda_k \left\{ \frac{1}{\sqrt{n}} \sum_{i=1}^n \phi_k(X_i) \right\}^2 \\ &\rightsquigarrow \frac{1}{2} \sum_{k=1}^{\infty} \lambda_k Z_k^2 \end{aligned}$$

其中 $\{Z_i\}$ 为 *i.i.d* 标准正态分布随机变量, 因为 $E_F \phi_k(X_i) = 0$, $E_F \phi_k^2(X_i) = 1$, $E_F \phi_j(X_i) \phi_k(X_i) = 0$. \square